

Santiago Herrera Tafur

Data Engineer Junior | Ingeniero de Sistemas | Máster en Big Data

Lisboa, Portugal (presencial, híbrido o remoto) | +351 920 787 540 | santyherrera12@gmail.com

LinkedIn: [linkedin.com/in/santiago-herrera-tafur-463887161](https://www.linkedin.com/in/santiago-herrera-tafur-463887161) | GitHub: github.com/santyherrera12 | Portafolio:

santyherrera12.github.io/Portafolio

PERFIL PROFESIONAL

Ingeniero de Sistemas cursando un Máster en Big Data en la Universidad Europea de Madrid, con enfoque en Data Engineering. Portafolio de 14 proyectos completados: pipelines ETL, arquitectura Medallion (Bronze/Silver/Gold) con dbt y PostgreSQL, streaming en tiempo real con Apache Kafka, procesamiento distribuido con Apache Spark (PySpark), APIs REST con FastAPI y despliegue en contenedores con Docker. Dominio sólido de SQL (JOINs, CTEs, funciones de ventana) y Python (Pandas). Busco un puesto de Data Engineer Junior, Analista de Datos o Desarrollador Backend; abierto a otras áreas de TI.

COMPETENCIAS TÉCNICAS

Programación: Python, SQL, Shell scripting (Bash), JavaScript, HTML, CSS

Ingeniería de datos: Pipelines ETL, dbt, Apache Spark (PySpark), Apache Kafka, Data Lake, Data Warehouse, arquitectura Medallion (Bronze/Silver/Gold), web scraping (BeautifulSoup)

Bases de datos: PostgreSQL, MySQL, Oracle, SQL Server, MongoDB, Cassandra, Google BigQuery

Cloud y DevOps: Docker, Docker Compose, Git, GitHub, Linux/Unix, AWS (S3, IAM)

Backend: FastAPI, APIs REST, SQLAlchemy, Pydantic, Swagger UI

Análisis de datos y ML: Pandas, Scikit-learn, Random Forest, Prophet, predicción de series temporales, detección de anomalías

Visualización de datos: Power BI, Streamlit, Plotly, Matplotlib, React (Recharts)

Gobierno de datos: Catálogo de datos, glosario de negocio, linaje de datos, reglas de calidad de datos, RGPD (GDPR)

Herramientas: VS Code, Google Colab, Microsoft 365 (Excel avanzado)

PROYECTOS

Código disponible en github.com/santyherrera12

Plataforma de Análisis y Predicción de la Balanza Petrolífera — TFM (en curso)

Python, Pandas, Prophet, Streamlit, Plotly, Data Lake

- Data Lake Bronze/Silver/Gold que integra importaciones y exportaciones de la CNMC (3.906 registros, 14 productos, 2003–2026) mediante un pipeline modular de cinco módulos Python (bronze, silver, gold, forecast, visualize).
- Predicción de la balanza petrolífera de España hasta 2030 con Prophet; detección automática de anomalías y análisis del impacto de la crisis de 2008, la COVID-19 y la crisis energética de 2022.
- El análisis muestra que España redujo un 71 % su dependencia neta desde 2003; resultados presentados en una aplicación interactiva con Streamlit.

Data Warehouse con dbt y PostgreSQL

dbt, SQL, PostgreSQL, Docker

- Data Warehouse con arquitectura Medallion (Bronze, Silver, Gold): 9 modelos SQL versionados y 17 tests automáticos de calidad de datos.

Pipeline de streaming en tiempo real

Python, Apache Kafka, MongoDB, Docker Compose

- Pipeline en contenedores: un producer genera una transacción cada 2 segundos, la publica en Apache Kafka y un consumer la persiste en MongoDB.

Pipeline de datos con Apache Spark

PySpark, Python

- Procesamiento distribuido de 100.000 transacciones: limpieza, agregaciones distribuidas y funciones de ventana (RANK, LAG).

API REST con FastAPI y PostgreSQL

Python, FastAPI, SQLAlchemy, Pydantic, PostgreSQL, Docker

- Backend con arquitectura en capas: endpoints CRUD, validación con Pydantic, ORM con SQLAlchemy, PostgreSQL en Docker y documentación con Swagger UI.

Análisis avanzado con SQL

SQL, PostgreSQL, Docker

- Consultas de negocio sobre una base de datos e-commerce de 5 tablas con JOINs múltiples, subconsultas, CTEs y funciones de ventana (RANK, LAG, PARTITION BY): ingresos por cliente, meses más rentables y evolución del ticket medio.

Pipeline de Machine Learning — Predicción de abandono laboral

Python, Scikit-learn, Pandas, FastAPI

- Modelo Random Forest (95,5 % de accuracy) con entrenamiento, métricas de evaluación y API de predicción en tiempo real con FastAPI.

Dashboard analítico cloud con BigQuery y Power BI

Google BigQuery, SQL, Power BI

- Consultas SQL analíticas sobre un dataset de ventas de videojuegos en BigQuery para responder preguntas de negocio; dashboard ejecutivo con 5 visualizaciones conectado directamente a BigQuery.

Pipeline ETL — Datos meteorológicos

Python, Pandas, API REST, python-dotenv

- Pipeline modular Extract, Transform y Load que obtiene datos de la API OpenWeatherMap para múltiples ciudades y los carga en un CSV histórico; entorno virtual y configuración con .env.

Web scraping y análisis automatizado

Python, BeautifulSoup, Pandas

- Extracción de 980 libros de 50 páginas web, limpieza con Pandas y generación de un informe de análisis (módulos scraper, analysis y main).

Gobierno de datos — Dataset Airbnb Madrid (académico)

Python, Google Colab

- Glosario de negocio, catálogo de datos, linaje de datos y análisis RGPD; reglas de calidad de datos implementadas en Python.

Otros proyectos: Aplicación full stack (React, FastAPI, PostgreSQL, Docker); app interactiva de análisis de ventas (Streamlit, Plotly); dashboard analítico (React, Recharts); aplicación web en JavaScript; landing page responsive (HTML, CSS); visualización de datos con D3.js.

FORMACIÓN ACADÉMICA

Piscine — Programa intensivo de selección | Sep 2026

42 Lisboa (42 Network) — Lisboa, Portugal

- Piscine de 26 días a jornada completa, completada: ejercicios diarios de programación en entorno Unix/Linux, shell scripting (Bash) y control de versiones con Git, bajo la metodología peer-to-peer de 42.

Máster en Big Data | Nov 2025 - Sep 2026 (previsto)

Universidad Europea de Madrid — Madrid, España (Online)

- Módulos: bases de datos NoSQL (MongoDB, Cassandra, Redis), Apache Kafka, Hadoop, Apache Spark (PySpark), arquitecturas cloud (AWS, Docker, Kubernetes), Google BigQuery, machine learning (Random Forest, K-Means, redes neuronales), visualización de datos (Power BI, D3.js), gobierno de datos, gestión de proyectos Big Data, Scala.

Ingeniería de Sistemas | Ago 2019 - Oct 2025

Universidad Cooperativa de Colombia — Ibagué, Colombia

- Desarrollo de software, bases de datos relacionales (SQL, Oracle), diseño y administración de bases de datos, redes y comunicaciones, arquitectura de sistemas.

Tecnólogo en Sistemas | Ene 2016 - Jun 2017

SENA — Centro de Comercio y Servicio, Colombia

- Análisis y desarrollo de sistemas de información.

CERTIFICACIONES Y CURSOS

- Oracle Database SQL (1Z0-071) — en preparación
- Diseño y Desarrollo de Sitios Web — SENA (2019)

IDIOMAS

Español: Nativo | Inglés: B1-B2 (en formación activa) | Portugués: B1 (en formación activa)

APTITUDES

Resolución de problemas, pensamiento analítico, aprendizaje autónomo, trabajo en equipo en entornos técnicos, mejora continua.