

Santiago Herrera Tafur

Data Engineer Júnior | Engenheiro de Sistemas | Mestrado em Big Data

Lisboa, Portugal (presencial, híbrido ou remoto) | +351 920 787 540 | santyherrera12@gmail.com

LinkedIn: [linkedin.com/in/santiago-herrera-tafur-463887161](https://www.linkedin.com/in/santiago-herrera-tafur-463887161) | GitHub: github.com/santyherrera12 | Portefólio:

santyherrera12.github.io/Portafolio

PERFIL PROFISSIONAL

Engenheiro de Sistemas a frequentar o Mestrado em Big Data na Universidad Europea de Madrid, com foco em Data Engineering. Portefólio de 14 projetos concluídos: pipelines ETL, arquitetura Medallion (Bronze/Silver/Gold) com dbt e PostgreSQL, streaming em tempo real com Apache Kafka, processamento distribuído com Apache Spark (PySpark), APIs REST com FastAPI e implementação em contentores com Docker. Domínio sólido de SQL (JOINS, CTEs, window functions) e Python (Pandas). Procuro uma função de Data Engineer Júnior, Analista de Dados ou Programador Backend; aberto a outras áreas de TI.

COMPETÊNCIAS TÉCNICAS

Programação: Python, SQL, Shell scripting (Bash), JavaScript, HTML, CSS

Engenharia de dados: Pipelines ETL, dbt, Apache Spark (PySpark), Apache Kafka, Data Lake, Data Warehouse, arquitetura Medallion (Bronze/Silver/Gold), web scraping (BeautifulSoup)

Bases de dados: PostgreSQL, MySQL, Oracle, SQL Server, MongoDB, Cassandra, Google BigQuery

Cloud e DevOps: Docker, Docker Compose, Git, GitHub, Linux/Unix, AWS (S3, IAM)

Backend: FastAPI, APIs REST, SQLAlchemy, Pydantic, Swagger UI

Análise de dados e ML: Pandas, Scikit-learn, Random Forest, Prophet, previsão de séries temporais, deteção de anomalias

Visualização de dados: Power BI, Streamlit, Plotly, Matplotlib, React (Recharts)

Governança de dados: Catálogo de dados, glossário de negócio, linhagem de dados, regras de qualidade de dados, RGPD (GDPR)

Ferramentas: VS Code, Google Colab, Microsoft 365 (Excel avançado)

PROJETOS

Código disponível em github.com/santyherrera12

Plataforma de Análise e Previsão da Balança Petrolífera — Dissertação de Mestrado (em curso)

Python, Pandas, Prophet, Streamlit, Plotly, Data Lake

- Data Lake Bronze/Silver/Gold que integra importações e exportações da CNMC (3.906 registos, 14 produtos, 2003–2026) através de um pipeline modular de cinco módulos Python (bronze, silver, gold, forecast, visualize).
- Previsão da balança petrolífera de Espanha até 2030 com Prophet; deteção automática de anomalias e análise do impacto da crise de 2008, da COVID-19 e da crise energética de 2022.
- A análise mostra que Espanha reduziu em 71% a sua dependência líquida desde 2003; resultados apresentados numa aplicação interativa em Streamlit.

Data Warehouse com dbt e PostgreSQL

dbt, SQL, PostgreSQL, Docker

- Data Warehouse com arquitetura Medallion (Bronze, Silver, Gold): 9 modelos SQL versionados e 17 testes automáticos de qualidade de dados.

Pipeline de streaming em tempo real

Python, Apache Kafka, MongoDB, Docker Compose

- Pipeline em contentores: um producer gera uma transação a cada 2 segundos, publica-a no Apache Kafka e um consumer persiste-a no MongoDB.

Pipeline de dados com Apache Spark

PySpark, Python

- Processamento distribuído de 100.000 transações: limpeza, agregações distribuídas e window functions (RANK, LAG).

API REST com FastAPI e PostgreSQL

Python, FastAPI, SQLAlchemy, Pydantic, PostgreSQL, Docker

- Backend com arquitetura em camadas: endpoints CRUD, validação com Pydantic, ORM com SQLAlchemy, PostgreSQL em Docker e documentação com Swagger UI.

Análise avançada com SQL

SQL, PostgreSQL, Docker

- Consultas de negócio sobre uma base de dados de e-commerce com 5 tabelas, usando JOINs múltiplos, subconsultas, CTEs e window functions (RANK, LAG, PARTITION BY): receita por cliente, meses mais rentáveis e evolução do valor médio por encomenda.

Pipeline de Machine Learning — Previsão de abandono de colaboradores

Python, Scikit-learn, Pandas, FastAPI

- Modelo Random Forest (95,5% de accuracy) com treino, métricas de avaliação e API de previsão em tempo real com FastAPI.

Dashboard analítico cloud com BigQuery e Power BI

Google BigQuery, SQL, Power BI

- Consultas SQL analíticas sobre um dataset de vendas de videojogos no BigQuery para responder a questões de negócio; dashboard executivo com 5 visualizações ligado diretamente ao BigQuery.

Pipeline ETL — Dados meteorológicos

Python, Pandas, API REST, python-dotenv

- Pipeline modular Extract, Transform e Load que obtém dados da API OpenWeatherMap para várias cidades e os carrega num CSV histórico; ambiente virtual e configuração com .env.

Web scraping e análise automatizada

Python, BeautifulSoup, Pandas

- Extração de 980 livros de 50 páginas web, limpeza com Pandas e geração de um relatório de análise (módulos scraper, analysis e main).

Governança de dados — Dataset Airbnb Madrid (académico)

Python, Google Colab

- Glossário de negócio, catálogo de dados, linhagem de dados e análise RGPD; regras de qualidade de dados implementadas em Python.

Outros projetos: Aplicação full stack (React, FastAPI, PostgreSQL, Docker); app interativa de análise de vendas (Streamlit, Plotly); dashboard analítico (React, Recharts); aplicação web em JavaScript; landing page responsiva (HTML, CSS); visualização de dados com D3.js.

FORMAÇÃO ACADÉMICA

Piscine — Programa intensivo de seleção | Set 2026

42 Lisboa (42 Network) — Lisboa, Portugal

- Piscine de 26 dias a tempo inteiro, concluída: exercícios diários de programação em ambiente Unix/Linux, shell scripting (Bash) e controlo de versões com Git, segundo a metodologia peer-to-peer da 42.

Mestrado em Big Data | Nov 2025 - Set 2026 (previsto)

Universidad Europea de Madrid — Madrid, Espanha (Online)

- Módulos: bases de dados NoSQL (MongoDB, Cassandra, Redis), Apache Kafka, Hadoop, Apache Spark (PySpark), arquiteturas cloud (AWS, Docker, Kubernetes), Google BigQuery, machine learning (Random Forest, K-Means, redes neurais), visualização de dados (Power BI, D3.js), governação de dados, gestão de projetos Big Data, Scala.

Licenciatura em Engenharia de Sistemas | Ago 2019 - Out 2025

Universidad Cooperativa de Colombia — Ibagué, Colômbia

- Desenvolvimento de software, bases de dados relacionais (SQL, Oracle), conceção e administração de bases de dados, redes e comunicações, arquitetura de sistemas.

Tecnólogo em Sistemas | Jan 2016 - Jun 2017

SENA — Centro de Comercio y Servicio, Colômbia

- Análise e desenvolvimento de sistemas de informação.

CERTIFICAÇÕES E CURSOS

- Oracle Database SQL (1Z0-071) — em preparação
- Design e Desenvolvimento de Websites — SENA (2019)

IDIOMAS

Espanhol: Língua materna | Inglês: B1-B2 (em formação ativa) | Português: B1 (em formação ativa)

COMPETÊNCIAS TRANSVERSAIS

Resolução de problemas, raciocínio analítico, aprendizagem autónoma, trabalho em equipa em ambientes técnicos, melhoria contínua.